Assistant Scolarité — Application RAG pour l'École d'Ingénieurs Hélianthe

Rapport de projet — Module RAG, Université Mundiapolis (3ACINFO) — Pr. Habib Ayad

Auteurs :Moussa Diajite — Octobre 2026

1. Objectif et périmètre

L'application répond aux questions des étudiants de l'École d'Ingénieurs Hélianthe (EIH, école fictive) en s'appuyant uniquement sur sept documents officiels : règlement des études, guide des stages et du PFE, charte de mobilité, calendrier, guide de la vie étudiante, FAQ et note de service n° 2026-14. Elle doit citer ses sources, refuser de répondre quand l'information est absente, et appliquer le texte le plus récent lorsqu'un document en modifie un autre (ici la note de service, qui modifie le guide des stages), sans règle écrite en dur pour ce corpus. Le livrable comprend un backend FastAPI, un frontend Angular, des tests pytest et un script d'évaluation reproductible.

2. Architecture

Ingestion (une fois) : PDF → extraction → découpage → embeddings → ChromaDB.

Question (à chaque requête) : interface Angular → `POST /api/ask` → recherche top-k → contrôle du seuil → ajout des documents modificatifs → prompt → LLM → contrôle des citations → réponse et sources.

Couche	Choix
Backend	Python 3.11, FastAPI, Pydantic v2, gestionnaire `uv`
Extraction	`pdfplumber` (texte, tableaux, métadonnées de la page 1)
Embeddings	`intfloat/multilingual-e5-small`, préfixes `passage:` et `query:`
Base vectorielle	ChromaDB persistante, distance cosinus, une collection par stratégie de découpage
LLM	`openai/gpt-oss-120b` via l'API Groq, température 0, clé dans `.env`

Couche	Choix
Frontend	Angular (composants standalone, `RagApiService`), TypeScript

Le découpage et le prompt sont écrits à la main, sans LangChain ni LlamaIndex.

3. Choix techniques

Extraction. Les métadonnées (référence, type, date, version, statut) sont lues dans le tableau clé-valeur de la page 1, la date française étant convertie en format ISO. Les en-têtes et pieds de page répétés sont retirés par expression régulière. Chaque ligne de tableau est réécrite sous la forme « En-tête : valeur — En-tête : valeur », ce qui conserve le lien entre une ligne et ses colonnes (calendrier, charte de mobilité). Les lignes de tableau sont replacées dans l'ordre de lecture avec le texte voisin.

Découpage. Deux stratégies : (a) fenêtre fixe de 500 caractères avec 100 de chevauchement, coupée à l'espace ; (b) découpage structurel, un fragment par article, question-réponse, rubrique ou bloc de tableau, coupé aux frontières de lignes au-delà de 900 caractères avec répétition du titre. Chaque fragment a un identifiant stable (`référence:stratégie:numéro`) et porte fichier, référence, type, date, version, statut, page et section. La stratégie structurelle produit 100 fragments. Le texte vectorisé ajoute au contenu le titre du document et la section, pour qu'un intitulé comme « Article 14 — Session de rattrapage » compte dans la similarité.

Indexation et recherche. L'ingestion est idempotente : écriture par *upsert* sur des identifiants stables et suppression des fragments devenus obsolètes. Le score est `1 - distance cosinus`. Le nombre de fragments `k` (5 par défaut) et le filtre par type de document sont configurables.

Gestion des versions sans règle en dur. Un document dont le statut contient « modifie » et cite une autre référence reçoit un champ `amends` (ici, la note 2026-14 modifie `EIH-SRE-GUIDE-2026`). Après la recherche, si un fragment provient d'un document modifié, les fragments pertinents du document modificatif sont ajoutés au contexte. Le prompt présente chaque fragment avec sa référence, sa date et son statut, plus la mention « CE DOCUMENT MODIFIE … » le cas échéant, et impose de retenir le texte modificatif en le signalant.

Prompt et contrôles. Le prompt impose de répondre uniquement à partir des fragments, de citer chaque affirmation par `[n]`, de refuser par la phrase exacte « Je ne trouve pas cette information dans les documents de l'École. », de privilégier le document modificatif et de détailler les calculs. Trois contrôles s'ajoutent côté code : (1) si le meilleur score est inférieur au seuil, refus sans appeler le LLM ; (2) tout numéro cité doit correspondre à un

fragment fourni, sinon il est signalé dans `invalid_citations` ; (3) une réponse sans aucune citation valide est traitée comme un refus. Le refus est toujours renvoyé sous sa forme exacte.

Seuil de refus. Avec un seuil initial de 0,7, aucune des 4 questions hors corpus n'était refusée. La mesure du meilleur score donne 0,75 à 0,81 pour les questions hors corpus et au moins 0,86 pour celles du corpus (stratégie structurelle) ; le seuil a été fixé à 0,83. Il sépare aussi les groupes avec la stratégie fixe (hors corpus ⩽ 0,8125, corpus ⩾ 0,8547).

4. Évaluation

4.1 Protocole

Le jeu de test (`eval/questions.json`) compte 36 questions. 26 ont leur réponse dans le corpus : 13 simples, 4 de calcul, 6 de version, 1 dont la réponse est répartie sur plusieurs fragments et 2 qui croisent plusieurs documents. 10 doivent être refusées : 4 hors corpus et 6 sur un sujet du corpus dont la réponse précise est absente (par exemple le prix d'un repas). Pour chaque question, la réponse attendue et le fragment justificatif sont rédigés à partir du texte extrait des documents. Le script `eval/run_eval.py` mesure la recherche (any@k, all@k, MRR, refus par le seuil) sans LLM, puis le bout en bout (décision trouvé/refus, mots-clés attendus, validité des citations, citation du document modificatif). Chaque exécution écrit un rapport JSON dans `eval/results/` .

4.2 Recherche : découpage fixe ou structurel (26 questions du corpus, k = 5)

Mesure	Structurel	Fixe (500/100)
any@1	18/26 (69 %)	18/26 (69 %)
any@3	25/26 (96 %)	24/26 (92 %)
any@5	25/26 (96 %)	26/26 (100 %)
MRR	0,821	0,821
Faux refus par le seuil de 0,83	0/26	0/26
Questions hors corpus refusées par le seuil	4/4	4/4

Sources : exécution du 30/10/2026 à 06:12 (structurel) et à 05:43 (fixe, recherche seule, même jeu de questions à la formulation de Q05 près).

Les deux stratégies obtiennent le même MRR mais échouent sur des questions différentes :

- **Q18** (dates des soutenances de stage technique) : le fragment structurel du calendrier regroupe six événements ; la ligne cherchée n'en est qu'une partie et son embedding est dilué, si bien que la preuve n'apparaît pas dans le top 5. Les fenêtres de 500 caractères isolent mieux la ligne : le découpage fixe la retrouve au rang 4.
- **Q22** (critères de sélection de la mobilité) : la phrase « 60 %, 25 % et 15 % » est coupée par un saut de page entre deux fragments structurels, d'où un rang 2 ; le chevauchement du découpage fixe garde la phrase entière (rang 1).
- **Q12 et Q13** (délai de dépôt du rapport de PFE, règle modifiée par la note de service) : le découpage structurel place l'article 2 de la note aux rangs 1 et 2 grâce à son intitulé ; le découpage fixe le relègue aux rangs 3 et 4, vraisemblablement derrière le fragment du guide qui énonce l'ancienne règle de 10 jours.

On retient donc le découpage structurel par défaut : ses fragments sont lisibles et citables (article, page, section) et il traite mieux la règle des versions ; le découpage fixe est plus tolérant aux gros blocs de tableau.

Effet de k (structurel) : any@1 = 69 %, any@3 = 96 %, any@5 = 96 %. Passer de 1 à 3 fragments rattrape 7 questions dont la preuve est en rang 2 ou 3 ; au-delà, aucun gain sur ce jeu. Nous gardons k = 5 par marge pour les réponses multi-fragments et l'ajout du document modificatif. Le cas k = 8 n'a pas été mesuré (commande : `--ks 1 3 5 8`).

4.3 Bout en bout (structurel, k = 5, 36 questions)

Mesure	Résultat
Décision trouvé/refus correcte	34/36 (94 %)
Questions du corpus répondues	24/26 (92 %)
Mots-clés attendus présents	24/26 (92 %)
Citations valides	24/26 (92 %)
Document modificatif cité quand il le faut	6/6
Refus corrects, hors corpus	4/4
Refus corrects, même sujet sans réponse	6/6
Faux refus dans le corpus (LLM)	2/26 (Q05, Q18)
Latence moyenne	691 ms (environ 30 ms pour un refus par le seuil)

Le premier run complet donnait 33/36. Q15 était refusée à tort alors que le modèle avait répondu correctement : il avait écrit sa citation avec des crochets pleine chasse (« 【2】 ») que la vérification ne reconnaissait pas. La lecture des réponses brutes a révélé ce bug de

notre code ; une normalisation des crochets et un test dédié l'ont corrigé, et le run suivant donne 34/36 et 6/6 sur le document modificatif.

4.4 Exactitude et fidélité

La notation manuelle de 0 à 2 a été faite sur le rapport du 30/10 à 06:00 : 23 réponses sur 26 sont exactes et complètes (2/2) ; les 3 autres sont des refus à tort (0/2 : Q05, Q15, Q18), dont Q15 est corrigée depuis. Les calculs sont justes et détaillés (Q04 : 10,4/20 ; Q13 : 28 juin 2027 ; Q20 : 28 000 MAD) et la règle des versions est appliquée (18 semaines, 14 jours, annexe obligatoire sur l'IA, avec citation de la note 2026-14). Côté fidélité, aucune information étrangère aux fragments n'a été relevée, à une légère extrapolation près sur Q23 (le rôle du jury lors d'une soutenance à distance).

4.5 Deux niveaux de refus

Les questions hors corpus (scores 0,75 à 0,81) sont refusées par le seuil en une trentaine de millisecondes, sans appel au LLM. Les questions sur un sujet du corpus (scores 0,84 à 0,90) dépassent le seuil : il ne peut pas les refuser. C'est le prompt qui s'en charge (6/6), et le contrôle n° 3 rattrape les refus reformulés. Les deux niveaux sont complémentaires.

5. Analyse des échecs restants

Q18 — recherche. Les fragments du guide et de la charte, qui parlent d'une soutenance « en octobre » sans donner les dates, passent devant le fragment du calendrier ; le LLM refuse faute des dates, ce qui est cohérent avec le contexte reçu. Piste : limiter le nombre de lignes de tableau par fragment structurel. Cette piste est identifiée mais n'était pas appliquée à la date de rédaction.

Q05 — génération. La recherche est correcte (article 14, plafond de 12/20, au rang 1), mais le LLM refuse. Hypothèse, non confirmée : la note initiale du module est inconnue alors que l'article 14 retient la meilleure des deux notes, et l'article 9.2 (absence justifiée, note non plafonnée) figure dans le même contexte. La question a déjà été reformulée une fois sans effet ; la modifier encore reviendrait à ajuster le test au système, ce que nous évitons.

6. Limites

- Le seuil est calibré sur seulement 4 questions hors corpus, et évalué sur le jeu qui a servi à le calibrer : le résultat 0/26 faux refus n'est pas indépendant.
- Le jeu de test a été en partie ajusté après observation des échecs (formulation de Q05).

- Les mots-clés attendus sont un proxy automatique ; l'exactitude de 0 à 2 est notée à la main sur un seul run.
- La recherche est purement sémantique : les dates, chiffres et libellés exacts sont son point faible.
- Chaque question est indépendante, sans mémoire de conversation.
- `POST /api/ingest` n'est pas authentifié et l'API n'a pas de limitation de débit : à protéger avant tout déploiement.
- Il n'y a pas de test automatique côté frontend.

7. Conclusion et perspectives

Le système répond correctement à 24 questions du corpus sur 26, refuse correctement les 10 questions sans réponse et applique le texte modificatif sans règle propre au corpus. Les deux échecs restants ont des causes distinctes : un défaut de découpage (Q18) et un refus excessif du modèle sur un calcul à règles voisines (Q05). Les améliorations les plus prometteuses sont une recherche hybride (BM25 et vecteurs) ou un reranker pour les libellés exacts, un découpage qui limite les lignes de tableau par fragment, une calibration du seuil sur un jeu plus large et indépendant, et une mémoire de conversation.